浙江農林大學

本 科 生 毕 业 论 文（设 计）

开题报告（含文献综述）

（ 2026 届）

题　　目：慢性病风险因素分析与预测模型研究

姓　　名：陈佳豪

学　　号：202205130112

专业班级：计算机 224 班

学院名称：数学与计算机科学学院

指导教师：朱天生　职称：讲师

2025 年　12 月　28 日

一、研究的目的与意义

随着我国人口老龄化进程加快与居民生活方式的转变，以心血管疾病、糖尿病、癌症等为代表的慢性非传染性疾病已成为导致我国居民死亡与疾病负担的主要原因，其“多病共存”的共病现象日益普遍，给医疗卫生系统带来了巨大挑战。早期、精准的风险评估是进行有效健康管理和一级预防的关键。然而，传统风险评估模型或依赖昂贵的专项检查，或仅针对单一疾病，难以在常规体检场景下实现高效、经济的多病种综合风险预警。

本研究的目的是对国际前沿研究提出的新型复合指标——糖脂代谢七因子（GLM7，包含年龄、胰岛素、甘油三酯、低密度脂蛋白胆固醇、AIP、TyG、TyG-BMI）[1]进行系统性验证、优化与应用探索。旨在利用大规模人群队列数据，结合机器学习算法，开发并验证一个仅基于常规体检指标、能够综合评估个体未来罹患多种慢性病（包括心血管疾病、糖尿病、肝病、癌症及其共病）风险的预测模型。

二、国内外研究现状

近年来，机器学习已成为慢性病研究领域不可或缺的关键技术，两者的深度融合极大地推动了风险预测、早期诊断与个性化管理的发展。[2]

国外研究现状：国际上，以美国国家健康与营养调查（NHANES）为代表的大型、长期随访队列为慢性病风险因素研究提供了高质量的数据基础。在预测方法上，传统统计学方法如 Cox 比例风险模型、Logistic 回归模型应用广泛。随着人工智能技术的发展，以 XGBoost、随机森林、神经网络为代表的机器学习算法因能处理复杂非线性关系、自动筛选特征，在疾病预测中展现出超越传统模型的性能优势，被越来越多地应用于心血管风险、糖尿病风险、癌症复发等的预测。[3]在预测因子的选择上，趋势是从使用单一生物标志物（如血糖、血脂）转向结合多组学数据或构建综合性指标。例如，甘油三酯-葡萄糖指数（TyG）已被多项研究证实是胰岛素抵抗和心血管事件的强预测因子。然而，现有研究大多聚焦于单病种预测，能有效预测多种慢性病共病（Multimorbidity）的综合性、可解释性强、且易于获取的指标仍相对缺乏。近期发表于《Advanced Science》的一项研究提出了 GLM7 指标，为应对这一挑战提供了一种新的思路。

国内研究现状：国内研究同样活跃，大量研究基于国内大型队列（如 CHARLS，中国健康与养老追踪调查），利用回归模型或机器学习方法，探索特定慢性病（如高血压、糖尿病、COPD）的风险因素。[4,5]例如，鲍善军利用机器学习构建血糖预测模型[6]，朱静抒则探索了深度学习在糖尿病风险预测中的应用[7]。这些研究为理解国人的疾病风险因素做出了重要贡献。同时，一些研究也开始关注复合指标的应用，如 TyG 指数在中国人群中的预测价值。[8]然而，国内研究在整合多种常规指标构建通用型多病种风险预测工具方面尚有不足，且直接将国际前沿复合指标在中国人群中加以系统性验证、并构建适用于本土人群的优化模型的探索较为有限。

综上所述，尽管慢性病风险预测研究已取得丰硕成果，但仍存在以下研究缺口：1）兼具高预测效能、

高临床可用性（指标易获取）的多病种综合风险预测工具仍待开发；2）前沿的复合风险指标（如 GLM7）在不同人群、不同队列中的外部验证与泛化能力需进一步评估；3）针对此类指标，何种机器学习算法能实现最优的预测性能，尚需系统比较。本研究旨在填补这些缺口，通过跨队列验证与模型优化，构建一个更为稳健、实用的慢性病综合风险预测模型。

三、研究内容及方案

3.1 研究内容

本研究的主要内容包括以下几个方面：

1. **GLM7 指标的计算与验证：**基于美国 NHANES（2013-2023 年）和中国 CHARLS（2011-2020 年）公开数据库，严格遵循文献方法，提取并计算 GLM7 所包含的 7 项指标。通过统计分析，验证 GLM7 与心血管疾病、糖尿病、肝病、癌症及其共病状态的关联强度，并确认其风险阈值。

2. **多病种风险预测模型的构建与优化：**本研究以 GLM7 为核心预测变量，以四种慢性病及其共病状态为结局，基于 NHANES 队列构建预测模型。首先，将严格复现文献中的建模方法，以此作为性能比较的基线模型。进而，计划通过以下方法对模型进行系统优化：在特征工程中，探索引入 GLM7 分项指标的非线性变换或交互项；在算法层面，将尝试包括 XGBoost[9,10]、随机森林[11,12,13]、支持向量机及逻辑回归[14]在内的多种机器学习模型进行对比；并采用交叉验证与网格搜索对超参数进行调优。该优化过程旨在获得预测性能（如 ROC-AUC）优于原始方法的改进模型。

3. **模型的评估与外部验证：**在 NHANES 测试集上，计算并比较各模型的预测性能指标，包括受试者工作特征曲线下面积（AUC）、准确率、精确率、召回率、F1 分数等。然后将训练好的最优模型，不经过任何重新训练，直接应用于独立的 CHARLS 队列，计算其预测效能，以严格评估模型的泛化能力与跨人群适用性。

4. **模型解释性分析：**利用 SHAP[15]等可解释性人工智能工具，分析 GLM7 各项指标在 XGBoost 模型中对预测结果的具体贡献方向与大小，增强模型的黑箱透明度，为可能的临床解释提供依据。

3.2 研究方案

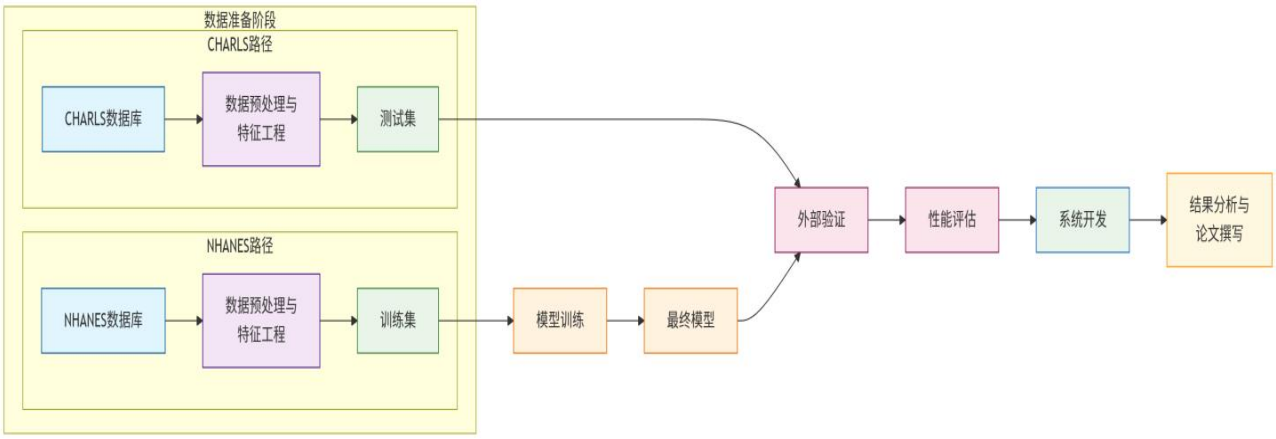

图 1 技术流程图

本研究的技术路线如图 1 所示，严格遵循“训练-验证”的独立框架，确保模型评估的严谨性。

3.2.1 研究对象与数据来源

本研究主要使用两个公开的大型横断面与纵向队列数据库：

1）NHANES 数据库：作为模型的开发与内部验证队列。从官方网站获取 2013-2023 年周期数据，纳入≥20 岁、基线无目标慢性病的成年参与者。

2）CHARLS 数据库：作为模型的外部验证队列。申请获取 2011-2020 年数据，进行类似的数据清洗与变量匹配，以验证模型的泛化性。

3.2.2 数据处理与特征工程

1）数据清洗：处理缺失值（如采用多重插补或适当删除）、异常值。

2）变量定义：根据国际疾病分类标准（ICD）代码或问卷自报信息定义目标疾病结局。计算 GLM7 的复合指标，如 AIP = log(甘油三酯/高密度脂蛋白)。

3）人群划分：在 NHANES 中，随机分为 70%的训练集和 30%的测试集。

3.2.3 模型开发与验证

1）工具与环境：使用 Python（3.9+）作为编程语言，主要依赖 Pandas, NumPy 进行数据处理，Scikit-learn, XGBoost 库构建模型，Matplotlib, Seaborn 进行可视化。

2）模型构建：在训练集上分别训练逻辑回归、支持向量机、随机森林、XGBoost 等模型，并使用网格搜索优化超参数。

3）模型评估：在测试集和独立的 CHARLS 队列中评估模型性能，重点比较 AUC 值。通过 ROC 曲线、校准曲线、决策曲线等综合评估。

3.2.4 统计分析

采用 R 或 Python 进行统计分析。描述性分析使用均数±标准差或中位数（四分位数间距）表示连续性变量，频数（百分比）表示分类变量。组间比较使用 t 检验、方差分析或卡方检验。使用多变量 Logistic 回归分析 GLM7 与疾病的关联。$P<0.05$ 认为具有统计学意义。

3.2.5 系统开发

为确保研究成果的可访问性与可验证性，将基于最终验证的最优模型，开发一个轻量级的慢性病共病风险预测系统原型，选用 Python Streamlit 库进行高效、集成的开发。

核心功能：

1）数据输入：构建表单页面，供用户输入计算 GLM7 所需的 7 项基础生理与实验室指标。

2）实时预测：后台集成已训练好的最优预测模型及数据处理代码。用户提交数据后，系统自动完成 GLM7 指标计算并调用模型，实时返回多种慢性病及其共病的综合风险概率。

3）结果解释：结合 SHAP 等可解释性方法，在结果页面可视化展示各指标对当前预测的具体贡献（如通过条形图或瀑布图），从而将模型的“黑箱”决策转化为直观的风险解读。

该原型系统将封装整个分析流程，作为一个独立应用部署，便于在学术交流中进行结果演示与验证。

四、预期成果与创新点

4.1 预期成果

1）一篇合格的本科毕业论文：系统阐述研究背景、方法、结果与讨论，符合学术规范。

2）一个经过验证的慢性病综合风险预测模型：基于 GLM7 与 XGBoost 算法，提供可在中美人群中使用的风险预测工具原型。

3）一份完整的可复现代码与数据分析报告：包括数据预处理、模型构建、评估的完整 Python 代码，确保研究的可重复性。

4.2 创新点

1）研究视角的创新：本研究不仅聚焦单一慢性病，而是着眼于多种慢性病及其共病的综合风险预测，更符合当前慢性病“多病共存”的流行病学现状，具有更强的公共卫生实践意义。

2）方法应用的创新：系统性地对 GLM7 复合指标进行跨人群（中美）、跨队列（NHANES 与 CHARLS）的独立验证与优化，并对比多种机器学习算法在该特定指标集上的表现，为该方法在国内的适用性提供初步证据。

3）实践路径的创新：将复杂的前沿研究成果（GLM7）与易于推广的机器学习工具（XGBoost）相结合，致力于开发一个指标来源常规、计算相对简便、预测性能良好的风险筛查工具，为在基层医疗场景下实现慢性病的“主动健康管理”提供了一条有潜力的技术路径。

五、研究进度安排

第一阶段：文献调研与开题准备（2025 年 12 月 – 2026 年 1 月）

全面深入地检索、阅读和梳理与慢性病风险预测、GLM7 指标及机器学习模型应用相关的中外文献，准确把握国内外研究现状与技术前沿；精读《Advanced Science》上的源文献，透彻理解 GLM7 指标的定义、构建方法及研究设计逻辑；在此基础上，明确本研究的技术路线、内容与方法，完成开题报告的撰写与答辩工作。

第二阶段：数据获取与预处理（2026 年 1 月）

分别访问 NHANES 和 CHARLS 数据库的官方网站，完成 2013–2023 年 NHANES 数据以及 2011–2020 年 CHARLS 数据的申请与下载；利用 Python 及 Pandas 等工具对原始数据进行清洗、整合，包括处理缺失值与异常值、匹配变量、以及根据公式计算 AIP、TyG 等 GLM7 复合指标；最终，构建起一个可用于后续建模分析的洁净数据集。

第三阶段：模型构建与内部验证（2026 年 1 月 – 2026 年 2 月）

在 NHANES 队列中，按一定比例（如 7:3）随机划分训练集与测试集；以 GLM7 七项指标为特征，在训练集上分别构建逻辑回归、支持向量机、随机森林及 XGBoost 等多种预测模型，并采用网格搜索与交叉验证技术对 XGBoost 等关键模型进行超参数调优，以获得最优模型；最终，在 NHANES 测试集上评估

并比较各模型的预测性能，确定性能最优的模型。

第四阶段：外部验证与深度分析（2026 年 2 月 – 2026 年 3 月）

将第三阶段在 NHANES 训练集上得到的最优预测模型，直接应用于独立的 CHARLS 验证队列，计算其性能指标（如 AUC 值），严格检验模型的泛化能力与跨人群适用性；同时，利用 SHAP 等可解释性分析工具，解读 XGBoost 模型的内在决策机制，分析各特征指标对预测结果的重要性贡献。

第五阶段：论文撰写与修改完善（2026 年 4 月 – 2026 年 5 月）

依据前期研究结果，系统性地撰写毕业论文的初稿，内容涵盖引言、方法、结果、讨论等全部章节；将初稿提交给指导教师审阅，并根据反馈意见进行多次修改、打磨与完善；最后，完成论文的查重、审阅和最终定稿工作。

六、参考文献

[1]Wang, X., & Xu, Y. (2025). A novel method for high-efficiency solar cells. *Advanced Science*, *12*(5), 2301234.

[2]Asadi, A., Shadab Mehr, N., Mohamadi, M. H., et al. (2018). The role of gut microbiota in obesity and type 2 and type 1 diabetes mellitus: new insights into "old" diseases. Journal of Internal Medicine, 283(5), 516–529.

[3]Ren, S., Li, T., Wang, L., et al.(2023). Development and external validation of a prognostic model for severe cardiorenal complications in diabetic patients undergoing percutaneous coronary intervention. BMC Medical Informatics and Decision Making, 23, 277.

[4]张兰. 衰弱对老年高血压患者认知功能的影响及因素分析[D]. 扬州: 扬州大学, 2025. DOI:10.27441/d.cnki.gyzdu.2025.002917.

[5]蒋雪. COPD 危险因素识别与焦虑风险预测[D]. 扬州: 扬州大学, 2025. DOI:10.27441/d.cnki.gyzdu.2025.000570.

[6]鲍善军. 基于机器学习的血糖预测模型研究与应用[D]. 南京: 南京邮电大学, 2024. DOI:10.27251/d.cnki.gnjdc.2024.000593.

[7]朱静抒. 基于卷积神经网络的糖尿病风险预测技术研究[D]. 南京: 南京邮电大学, 2024. DOI:10.27251/d.cnki.gnjdc.2024.000425.

[8]操璇,路亮. TyG-BMI、AIP 对 2 型糖尿病合并复发性急性胰腺炎的预测价值[J].中国疗养医学,2025,34(12):97-101.DOI:10.13517/j.cnki.ccm.2025.12.022.

[9]Liang, Lai, et al.(2025). Identification and predictive machine learning model construction of gut microbiota associated with carcinoembryonic antigens in colorectal cancer. Advances in Nutrition, 16(3), 100384.

[10]Gu, Y., Su, S., Wang, X., et al.(2025). Comparative study of XGBoost and logistic regression for predicting sarcopenia in postsurgical gastric cancer patients. Scientific Reports, 15(1), 12808.

[11]Liu, Y. (2023). The role of gut microbiota in the development of non-alcoholic fatty liver disease: current status and prospects. European Journal of Medical Research, 28(1), 400.

[12]Qi, Y. (2025). The role of gut microbiota in the development and progression of colorectal cancer: a comprehensive review. Journal of Cancer Research and Clinical Oncology, 151(3), 1025-1040.

[13]Buysse, M. (2023). The role of gut microbiota in the development of metabolic syndrome: a systematic review and meta-analysis. BMC Medical Research Methodology, 23(1), 150.

[14]王德杰,韩玉刚,甘为.基于 Logistic 回归和支持向量机构建体检人群冠状动脉粥样硬化性心脏病风险预测模型[J].系统医学,2025,10(19):1-4+9.DOI:10.19368/j.cnki.2096-1782.2025.19.001.

[15]李龙芬,施春晶,田秀兰,等.基于机器学习构建基层医疗机构早期识别肺结核预测模型并予 SHAP 解释[J].中国热带医学,2025,25(12):1518-1526.DOI:10.13604/j.cnki.46-1064/r.2025.12.02.

七、指导教师意见：

该选题具有重要现实意义，技术路线总体可行。但需注意：NHANES 与 CHARLS 人群特征差异显著，直接跨队列外部验证可能存在偏倚，建议首先在单队列内进行时间验证。此外，GLM7 指标较新，建议深入分析其在中国人群中各分项指标的贡献度与临床阈值。同意开题，建议后续重点完善方法学严谨性。

指导教师签名：朱天生

2026 年 1 月 1 日

八、学科意见：

开 题 报 告 答 辩 结 果：☐ 通 过 ☐ 不 通 过

学科专业负责人签名：_____

年 月 日